

Factores que influyen en el rendimiento académico de los estudiantes

Data Science II - Comisión 74260

Autor: Luciana Lanatti

Abstracto y Motivación

Motivación:

El rendimiento académico no depende solo de las horas de estudio, sino también de factores sociales, emocionales y de estilo de vida.

Este análisis busca identificar qué variables tienen mayor impacto en las notas finales de los estudiantes.

Audiencia:

- Instituciones educativas interesadas en políticas de mejora de desempeño.
- Investigadores y docentes que buscan comprender los hábitos que favorecen el aprendizaje.
- Estudiantes de Data Science interesados en aplicar técnicas de análisis multivariable.

Resumen de Metadata

Dataset de 1000 estudiantes con hábitos diarios, conducta académica y bienestar.

Origen: Kaggle. Dataset base enriquecido con información educativa y socioeconómica (World Bank API). Se consultó la API del Banco Mundial para obtener gasto per cápita en educación (AR). → *No se incluyó en el modelo por no aportar variación interna.*

Enriquecimiento: creación de variables derivadas (bienestar, horas/día, academic_potential).

Principales variables:

exam_score → rendimiento académico (target)

study_hours_per_day, sleep_hours, social_media_hours, netflix_hours

attendance_pct_clipped, wellbeing_score_norm, academic_potential (variables creadas)

screen_time_hours (nueva combinación)

Preguntas / Hipótesis de estudio

P1: ¿Los estudiantes que asisten más a clases obtienen mejores notas?

H1: Los estudiantes que asisten a clases con mayor regularidad, obtienen mejores notas.

P2 ¿Los hábitos de vida, como la alimentación, ejercicio, horas de sueño, influyen en las calificaciones?

H2: Los hábitos como la alimentación, el ejercicio y las horas de sueño influyen en el rendimiento académico

Preguntas / Hipótesis de estudio

P3: ¿Existe relación entre tiempo de ocio digital (redes y Netflix) y rendimiento académico?


H3: Estudiantes que dedican más horas al estudio obtienen mejores puntajes en el examen final.

H4: El uso intensivo de redes sociales y plataformas de streaming tiene un efecto negativo en el rendimiento académico.

P4: ¿Podemos crear un índice que sintetice el potencial académico de un estudiante?

H5: Es posible construir un índice compuesto - basado en variables como horas de estudio, asistencia, nivel educativo de los padres y bienestar emocional- que se relacione significativamente con el rendimiento académico (exam_score).

Visualización 1: Asistencia vs. Nota




El gráfico evidencia una clara relación entre la asistencia y el rendimiento académico.

Los estudiantes con asistencia alta (>90%) obtienen en promedio notas superiores a los grupos con asistencia media o baja.

Esto sugiere que la regularidad en la asistencia a clases es un factor relevante para el desempeño en exámenes.

Visualización 2: Bienestar y Rendimiento



Correlación entre bienestar y nota: 0.33


Descripción:

El gráfico muestra la relación que existe entre el bienestar general (horas de sueño, dieta, ejercicio, salud mental) y rendimiento académico (notas). Se observa una tendencia ascendente moderada: a mejor score de bienestar, mayor nota promedio.

Conclusión:

La correlación positiva indica que los hábitos de vida como la salud, horas de sueño, alimentación tienen afectación en el desempeño académico.

Visualización 3: Tiempo de Pantalla y Rendimiento



Correlación entre tiempo de pantalla y nota: -0.24

Descripción:


El gráfico muestra la asociación entre las horas diarias dedicadas a redes sociales y plataformas de streaming, y el rendimiento académico de los estudiantes.

Se observa una tendencia descendente: a mayor tiempo de pantalla, menor nota promedio.

Conclusión:

La correlación negativa indica que el uso excesivo de pantallas podría afectar el rendimiento académico, lo cual coincide con hallazgos previos sobre distracción y saturación cognitiva.

Visualización 4: Potencial Académico



Correlación potencial académico: 0.74

El índice de potencial académico muestra una correlación fuerte ($r = 0.78$) con las notas de examen, validando su utilidad como medida compuesta del desempeño esperado.

Este resultado sugiere que los factores incluidos en su cálculo (hábitos de estudio, asistencia, entorno familiar y bienestar) son predictores sólidos del rendimiento académico real.

Análisis inferencial

Para validar estadísticamente las hipótesis planteadas, se realizó un ANOVA de un factor, regresión múltiple y validación cruzada del índice (*academic_potential*)

- ✓ ANOVA confirmó diferencias significativas ($p < 0.001$) entre grupos según horas de estudio.
 - ✓ La regresión múltiple mostró que: estudiar más, dormir bien y menos screen time → predicen mayor rendimiento. Mientras que *social_media_hours* no resultó significativo.
 - ✓ El índice *academic_potential* mostró estabilidad en validación cruzada ($R^2 \approx 0.54$).
-

Modelado Predictivo

Modelos probados

- Regresión Lineal
- Random Forest
- Optimización de hiperparámetros: GridSearchCV + RandomizedSearchCV

Resultados finales

- **Regresión Lineal:** RMSE = 7.74 (estable, baja varianza)
- **Random Forest optimizado:** $R^2 = 0.747$ en test (mejor capacidad predictiva real)

Modelo	RMSE CV Promedio	Varianza	R^2 Test
Regresión lineal	7.74	baja	~0.60
Random Forest	7.89	un poco mayor	0.747

Modelo seleccionado: Random Forest optimizado

- ✓ Captura relaciones no lineales
 - ✓ Mejor desempeño en test (R^2 0.747)
 - ✓ Balance adecuado entre bias y varianza
 - ✓ Resultados más robustos para predicción real
-

Conclusiones finales

- ✓ El análisis muestra que el rendimiento académico es el resultado de una combinación de hábitos de estudio, bienestar y manejo del tiempo.
- ✓ Las horas de estudio, el sueño y la asistencia surgieron como los predictores más consistentes, mientras que el tiempo de pantalla tuvo un impacto negativo moderado.
- ✓ El índice *academic_potential* probó ser una medida estable y explicativa de estas dimensiones.
- ✓ En el modelado predictivo, el **Random Forest** optimizado fue el modelo con mejor desempeño en datos reales ($R^2 = 0.747$), capturando relaciones no lineales que otros métodos no lograron representar.